

딥러닝을 이용한 카메라 모듈 불량 분류

Camera Module Defect Classification using Deep Learning

김병근(과) 위로직스충북대학교 산업인공지능학과
류관희(충) 북대학교 소프트웨어학부 산업인공지능학과

요약

스마트폰 카메라 모듈 최종 검사 장비가 전통적인 머신 비전 기술인 주변 밝기 차이와 정상 품과 비교 방법으로 불량을 판정하고 있어, 검사 과정에서 발생하는 판정 정확도에도 영향을 미치며 불필요한 제비용이 추가로 발생된다. 이에 전통적인 머신 비전과 딥러닝 알고리즘 판정의 정확도를 비교해보고자 한다. 본 연구에서는 장비를 통해 동일한 조건에서 촬영된 고 해상도 광학 영상을 Resize Augmentation 해 25,000개로 생성하고, Resnet18 모델로 학습과 검증을 진행하였다. 동일한 해상도 카메라 모듈에 대해 19일 40% 검사 장비는 판정 정확도를 보였으며, 딥러닝 알고리즘의 분류로 진행한 결과 95.71% 정확도를 보였다. 스마트폰 카메라가 점차 고 해상도를 요구함에 따라 본 연구의 데이터 또한 픽셀을 선정하였다. 추가로 전체 데이터 량과 불균형인 불량 데이터를 추가 수집하여 비슷한 비율로 학습을 진행한다면 정확도가 더 높아질 것으로 기대한다.

주제어: 딥러닝, 불량 분류

Abstract

Smart-phone camera module final inspection equipment determines defects by comparing differences in ambient brightness, which is a traditional machine vision technology, and normal products, generating false swords. This also affects judgment accuracy, and unnecessary manufacturing costs are additionally incurred. Therefore, this study aims to compare the accuracy of traditional superstition vision and deep learning algorithm judgment.

In this study, high-resolution optical images taken under the same conditions through equipment were pre-processed into 25,000 images through Resize and Augmentation, and learning and verification were conducted with Resnet18 models. For the same resolution camera module of 48M, the inspection equipment showed 95.40% decision accuracy for one month, and the classification of the deep learning algorithm showed 95.71% accuracy.

Smart-phone cameras gradually require high resolution, 48M pixels were also selected for the data of this study. Additionally, it is expected that the accuracy will be higher if the learning is conducted at a similar rate to the additional collection of bad data that is disproportionated to the overall data volume.

Keywords: Deep Learning, Defect Classification, Resnet18

1. 서론

모든 제품 제□공정이 그렇듯이 Assembly() 완성 후 성능검사와 외관적인 검사를 진행하게 되며 스마트폰 카메라 모듈의 제□공정도 그러하다 점 차 고□로 발전되어 현재는 억화소 이상의 카메라 모듈이 제작되고 있어 눈에 보이지 않은 아주 작은 먼지(Particle)나 픽셀상에 표현이 되고 이는 제품 불량으로 이어진다

먼지는 부품(렌즈) 필터에 붙어 있거나 따라 흩날리거나 Blur 등의 얼룩 형태로 표현되며 대부분의 검사 장비는 주변 픽셀과의 밝기 차이와 정상 품과의 비교를 통해 불량 검출과 분류를 진행하고 있다. 이는 오검으로 이어져 재검사를 진행하게 되는데 불필요한 제□비용이 생산 규모에 따라 비례하여 발생하게 된다[1].

본 □문은 검사장비의 머신 비전 기술과 딥러닝 알고리즘 기반의 불량 분류의 정확도를 측정하여 비교하고 대체 가능한 기술인지를 살펴보고자 한다



Figure1 스마트폰 카메라 모듈

2. 본론

2.1 데이터 수집

48M(4800만화소) 카메라 모듈을 머신 비전 장비에서 검사 영상 수집하였으며 생산 제품과 장비 별 광원과 공정 환경의 차이로 인해 영상 데이터의 밝기 차이가 존재하였다

48M(8,000*6,000)픽셀로 촬영한 데이터를 저장하고 있으며는 Figure 2 불량 (a),(b) 데이터로 레이블링 한 결과이다




Figure2.1 스마트폰 카메라 모듈

2.2 데이터 전처리 및 증강

입력 데이터의 증강을 위해 90도 회전 (Rotation)하여 데이터 량을 증가 시켰다

<Figure2.1>에서 보는 바 와 같이 상하좌우 대칭형인 영상 데이터는 회전을 해도 입력 데이터에 영향이 없고 데이터 증강을 할 수 있는 장점이 있다

<Figure2.2>는 전 처리 후 딥러닝 입력 데이터를 나타낸다

원본		Input data 구분	Augmentation	
OK	NG		OK	NG
7,207	827	TRAIN (90%)	19,397	2,956
		TEST (10%)	2,155	328
8,034		계	21,552	3,284

Figure 2.2 데이터 증강 및 입력데이터 구분

2.3 구현 및 학습

일반적으로 영상분류를 위해 전통적으로 사용되는 딥러닝 기법으로는 CNN[2], 좀 더 개선된 방법으로 GoogleNet, VGG[2], ResNet[3] 등이 있다본 논문에서는 분류에 최적화된 ResNet [3]을 선택하였다

네트워크의 자체 전처리 객체가 TrainTest data를 차별화를 위해, TrainRandomCrop를 하였고, 또한 각각 수평과 수직으로 하도록 하였다

학습에 대한 파라미터 정의는 25 Epoch 위해 Batch size 4 배치하여데이터의 사이즈로 인한 학습시간을 줄이도록 하였다 . OverfittingUnderfitting는 선에서 배치사이즈를 선정하였다학습 스케줄러를 위한 Optimizer learning rate 0.001, 소화를 회피하기 위한 Momentum 0.9였으며, 마다 epoch을 감소 하도록 Gamma값을 설정하였다

또한 위 파라미터는 고정하되 가지를 구반하여 학습을 진행하였다Resnet18의 사전학습 모델의 가중치와 준비한 데이터 셋을 함께 학습하는 경우와두 번 제로 사전 학습 모델을 상수로 고정하고 데이터 셋 만 학습하는 방법이 었다후자의 경우 전자에 비해 학습 속도는 2배 빨랐지만 정확도에서는 덜 4.2%는 결과를 보였다

<Figure2.3> (Accuracy)기준은 분류를 정확히 한 개수를 데이터 셋 총 수량으로 나눈 값이다

구분	학습시간	정확도
사전 학습 + 데이터 셋	5211초	95.7%
고정 + 데이터 셋	21640초	91.6%

Figure2.3 학습 결과

3. 실험 결과

머신비전 검사장비의 정확도 수치의 신뢰도를 높이기 위해개월간의 데이터를 수집하여 최초 판정과 최종 판정을 구분 하였고수량이 아닌 비율로 혼돈 행렬(Confusion Matrix)을 정밀도 95.48%, 100%를 산출되었다 23.84%, F1-Score 40.96% 산출되었다

		최종 판정 (%)	
		불량(T)	양품(F)
최초 판정(%)	불량(T)	1.44	0.00
	양품(F)	4.60	93.96

Figure3.1 검사장비 혼돈행렬

딥러닝 기반의 정확도는 학습 시 정확하게 분류한 개 수를 전체 데이터 셋 개 수로 나누어 계산하여, 95.48%정확도를 보였다딥러닝 (Resnet18)사전학습모델과 데이터 셋을 함께 학습 경우의 정확도와 를(F1)머신 비전의 정확도는 딥러닝 모델이 93.96% 것으로 실험 결과가 도출되었다



Figure3.2 사전학습모델 가중치데이터 셋 학습

4. 결론 및 시사점

스마트폰 카메라 모듈 검사장비가 전통적인 룰 (RULE)기반 모델인 주변 밝기 차이와 정상 품과 비교 방법으로 불량을 판정하고 있어,오(점)를 발생시킨다(RULE)여겨지는 룰판정의 정확도는불필요한 각종 제□비용이 유발시키고 있다.이에 동일한 영상 데이터 환경에서 딥러닝 알고리즘으로 불량 분류 의 정확도를 비교해 보고자 하였다.

딥 러닝을 구현하기 위해동(4,800)상도만 화소)제품과 장비의 영상 데이터를 전 처리 과정 (ResizeAugmentation)25(양품 불량=87%(13%),Resized13 모델 가중치와 데이터 셋 전체를 학습과 검증 진행 하였다.

검사 장비는 1개월 간의 검사 결과 데이터를 바탕으로 혼돈 행렬(Confusion matrix) 정하였으며 95.40%로 집계되었으며딥 러닝은 정상 분류를 총 데이터 셋으로 나눈 결과 학습 정확도는 95.71%0.31% 나타났다 (Rule)결과로 나타난 룰기반 검사 장비는 정확도 뿐 만 아니라새로운 위치유형범위에 따

라 룰 (RULE) 업데이트 하는 여러 불합리한 요소들이 유발되는 단점이 있어,딥러닝 분류가 실제 현장에서 적용 가능한 대안이 될 수 있다고 판단된다.본 연구에 진행한 딥 러닝이 정확도에 □ 차이를 보이지 못 한 점은 데이터 셋의 불균형과 픽셀사이즈의 전처리 과정에서 한계가 있다고 판단되어,추가적으로 불량영상 데이터 수집과 증강한다면 정확도가 높아질 것으로 기대한다

감사의 글

“본 연구는 과학기술정보통신부 및 정보통신기술 평가원의 지역지능화혁신인재양(Grand ICT 센터)사업의 연구결과로 수행되었음 (IITP-2022-2020-0-01462)

참고 문헌

1. (주)답엔지니어링카메라모듈 검사 장비의 자동화를 위한 기계학습의 활용전차공학회지 2016.11.

2. S. Albawi, T. A. Mohammed and S. Al-Za "Understanding of a convolutional neural network," 2017 International Conference on Engineering and Technology (ICET), 2017, pp 1-6, doi: 10.1109/ICEngTechnol.2017.830818

3. Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, Deep Residual Learning for Image Recognition, CVPR, 2015, <https://doi.org/10.48550/arXiv.1512.03385>